Planejamento e Análise de Experimentos (EEE933)
Estudo de Caso 1

Pedro Vinícius, Samara Silva e Savio Vieira

10 de Agosto de 2020

```
## Registered S3 method overwritten by 'GGally':
##   method from
##   +.gg   ggplot2
```

Introdução

Lindsey (1996) define inferência estatística como o campo que se preocupa com o processo probabilístico relacionado a eventos já ocorridos e às ilações sobre a população que pode-se chegar com base nesse conhecimento, ou seja, trata-se de extrair conclusões para o universo de estudo a partir de observações empíricas ou processos estocásticos.

Neste trabalho, esse conceito será utilizado mediante a geração de dados experimentais da nova versão de um determinado software, seguida da análise comparativa quanto a variante já conhecida. Nessa perspectiva, é investigado se houve redução do custo médio de execução e/ou da variância fornecida. Para isso, em ambos os casos as hipóteses nulas foram definidas de maneira conservadora, partindo-se do pressuposto de que os parâmetros populacionais conhecidos foram mantidos na nova versão. Posteriormente foram estabelecidas condições iniciais quanto à quantidade de observações, junto à coleta de dados, análise da distribuição amostral e aplicação dos testes.

Nas próximas seções é feito o detalhamento de cada uma dessas etapas.

Descrição do Problema

Parte 1: Teste Sobre o Custo Médio

Planejamento dos Experimentos

A primeira fase desse experimento consiste em gerar uma amostra representativa do desempenho do novo software. Para isso, é necessário especificar o tamanho dessa amostra, considerando os critérios de análise pré-estabelecidos. A saber, nível de significância $\alpha = 0.01$, efeito relevante de $\delta^* = 4$, e poder de $\pi = 1 - \beta = 0.8$.

A esse respeito, o Poder do Teste assume especial relevância, pois é possível estimar o número de observações necessários com base nos critérios estatísticos pré-estabelecidos. DEFINIR PODER DO TESTE.

Todavia, para executar esse teste é necessário fornecer um dado inicial para variância, que ainda não é conhecida. A bibliografia sugere três maneiras de fazê-lo, ...

Considerando as vantagens e desvantagens de cada uma, optou-se por utilizar...

$$\begin{cases} H_0 : \mu = 50 \\ H_1 : \mu < 50 \end{cases}$$

```r
# Define the sample size to be used in this experiment
(params <- power.t.test(delta = delta_star,
             sd = sigma_n,
             sig.level = alpha,
             power = pi,
             type = "one.sample",
             alternative = "one.sided"))
```

```
##
##      One-sample t test power calculation
##
##               n = 65.45847
##           delta = 4
##              sd = 10
##       sig.level = 0.01
##           power = 0.8
##     alternative = one.sided
```

```r
# Number of observations
n <- ceiling(params$n)
```

Coleta dos Dados

```r
data_generation <- function(n){

  mre <- list(name = "recombination_bin", cr = 0.9)
  mmu <- list(name = "mutation_rand", f = 2)
  mpo <- 100
  mse <- list(name = "selection_standard")
  mst <- list(names = "stop_maxeval", maxevals = 10000)
  mpr <- list(name = "sphere", xmin = -seq(1, 20), xmax = 20 + 5 * seq(5, 24))

  sample <- c()
  # Generate n observations
  for (i in 1:n){
    observation <- ExpDE(mpo, mmu, mre, mse, mst, mpr,
                    showpars = list(show.iters = "none"))$Fbest
    sample <- c(sample, observation)
  }

  return(sample)

}
```

```r
# Random seed
set.seed(1007)

# Collect the sample with n observations
sample <- data_generation(n = n)

# Saves data to the csv file
write.table(sample, file = 'sample.csv', row.names = FALSE, col.names = FALSE)
```

Análise Exploratória de Dados

```r
# Histogram
histogram <- ggplot(data = as.data.frame(sample), mapping = aes(x = sample))
histogram + geom_histogram(lwd = 0.3, bins = 20, color = 'black', fill = 'gray') +
            scale_x_continuous(name = 'Amostra') +
            scale_y_continuous(name = 'Frequência')
```

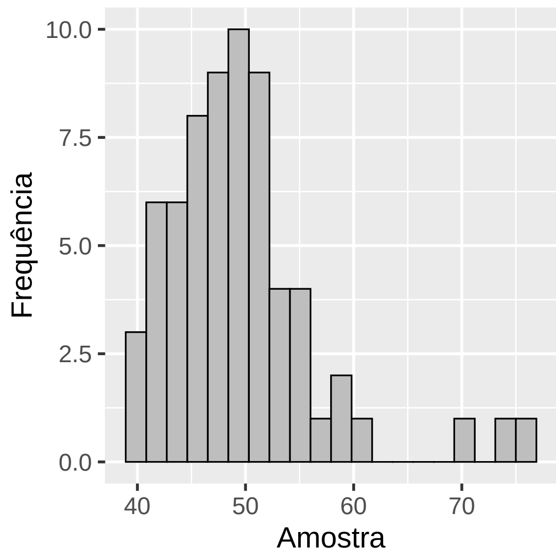


```r
# Boxplot
boxplot <- ggplot(data = as.data.frame(sample), mapping = aes(y = sample))
boxplot + geom_boxplot(lwd = 0.3) +
          scale_x_continuous(name = 'Amostra') +
          scale_y_continuous(name = '') +
          theme(axis.text.x = element_blank())
```

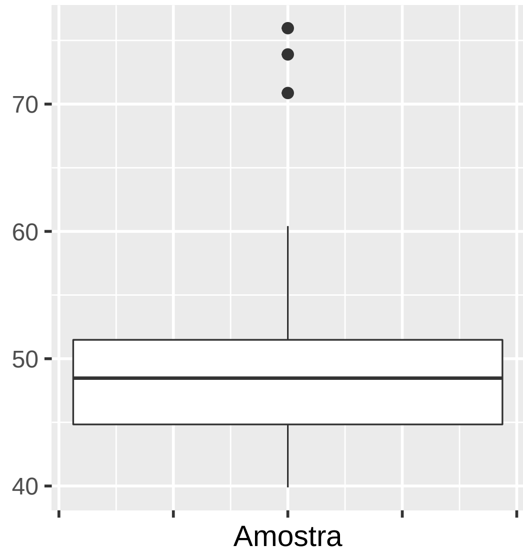


```r
# QQ-Plot
qqplot <- ggplot(data = as.data.frame(sample), mapping = aes(sample = sample))
```

```r
qqplot + geom_qq_line() +
         geom_qq() +
         scale_y_continuous(name = 'Amostra') +
         scale_x_continuous(name = 'Quantil')
```

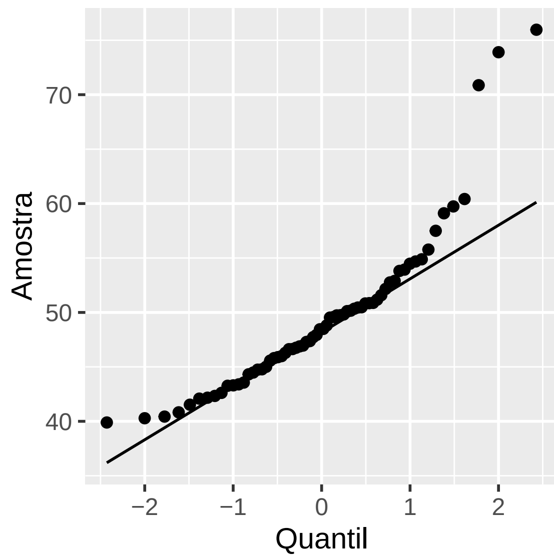

Análise Estatística

```r
# ------------ Hypothesis Testing ------------ #
(t_test <- t.test(x = sample,
                 mu = mu_c,
                 alternative = "less",
                 conf.level = conf_level))
```

```
##
##  One Sample t-test
##
## data:  sample
## t = -0.5742, df = 65, p-value = 0.2839
## alternative hypothesis: true mean is less than 50
## 99 percent confidence interval:
##     -Inf 51.5952
## sample estimates:
## mean of x
##  49.49419
```

```r
# Confidence Interval
CI <- t_test$conf.int[1:2]
```

Validação de Premissas

```r
# Wilcoxon Signed-Ranks Test, because it does not assume normality
(wilcoxon_test <- wilcox.test(x = sample,
                alternative = "less",
                mu = mu_c,
                paired = FALSE,
```

```r
                exact = NULL,
                correct = TRUE,
                conf.int = FALSE,
                conf.level = conf_level))
```

```
##
##  Wilcoxon signed rank test with continuity correction
##
## data:  sample
## V = 820, p-value = 0.03433
## alternative hypothesis: true location is less than 50
```

Parte 2: Teste Sobre a Variância do Custo

Planejamento dos Experimentos

$$\begin{cases} H_0 : \sigma^2 = 100 \\ H_1 : \sigma^2 < 100 \end{cases}$$

Conclusões

Referências

LINDSEY, James K. Parametric statistical inference. Oxford University Press, 1996.